



(12) 发明专利申请

(10) 申请公布号 CN 113298021 A

(43) 申请公布日 2021. 08. 24

(21) 申请号 202110654551.X

G06K 9/62 (2006.01)

(22) 申请日 2021.06.11

G06N 3/04 (2006.01)

G06N 3/08 (2006.01)

(71) 申请人 宿州学院

地址 234000 安徽省宿州市埇桥区朱仙庄
镇二铺村

申请人 淮北市思苑科技有限公司

(72) 发明人 李俊强 王超 田文泉 陈国龙
李文胜 武磊 张平杰

(74) 专利代理机构 合肥昊晟德专利代理事务所
(普通合伙) 34153

代理人 何梓秋

(51) Int. Cl.

G06K 9/00 (2006.01)

G06K 9/32 (2006.01)

G06K 9/46 (2006.01)

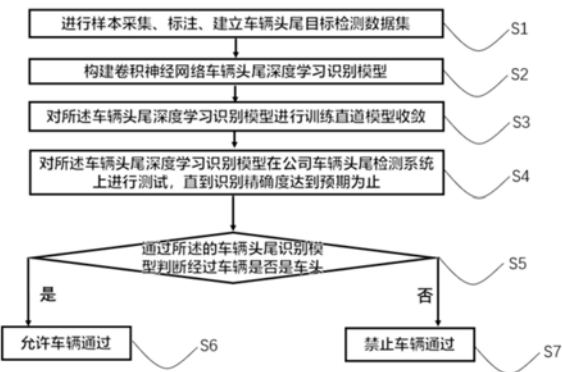
权利要求书2页 说明书5页 附图3页

(54) 发明名称

基于卷积神经网络的矿区运输车辆头尾识别方法及系统

(57) 摘要

本发明公开了基于卷积神经网络的矿区运输车辆头尾识别方法及系统,属于视觉识别技术领域,包括以下步骤:S1:进行样本采集、标注,建立车辆头尾目标检测数据集;S2:构建卷积神经网络车辆头尾深度学习识别模型;S3:对车辆头尾深度学习识别模型进行训练直到模型收敛,获得最优模型;S4:对最优模型在测试集上进行测试,直到识别精确度达到预期为止;则最优模型为最终车辆头尾识别模型;S5:通过最终车辆头尾识别模型判断车辆图片是否是车头图片;若是则允许车辆通过,否则禁止车辆通过。本发明采用改进的深度学习识别算法,进行训练直到收敛,然后对车辆进行快速识别,解决了矿区车辆头尾识别的问题,提高了车辆头尾检测的效率。



1. 基于卷积神经网络的矿区运输车辆头尾识别方法, 其特征在于, 包括以下步骤:

S1: 数据集获取

进行样本采集、标注, 建立车辆头尾目标检测数据集;

S2: 模型构建

构建卷积神经网络车辆头尾深度学习识别模型;

S3: 模型训练

对车辆头尾深度学习识别模型进行训练直到模型收敛, 获得最优模型;

S4: 模型测试

对最优模型在进行测试, 直到识别精确度达到预期为止: 则最优模型为最终车辆头尾识别模型;

S5: 检测判断

通过最终车辆头尾识别模型判断经过车辆的图片是否是车头图片; 若是则允许车辆通过, 否则禁止车辆通过。

2. 根据权利要求1所述的基于卷积神经网络的矿区运输车辆头尾识别方法, 其特征在于: 在所述步骤S1中, 采集矿区运输车辆车头的样本与矿区运输车辆车尾的图片样本, 并通过人工手动将图片样本分成车头和车尾两类。

3. 根据权利要求2所述的基于卷积神经网络的矿区运输车辆头尾识别方法, 其特征在于: 在所述步骤S1中, 矿区运输车辆车头的样本与矿区运输车辆车尾的图片样本数量均大于等于10000张。

4. 根据权利要求1所述的基于卷积神经网络的矿区运输车辆头尾识别方法, 其特征在于: 在所述步骤S2中, 车辆头尾深度学习识别模型包括依次间隔设置的五个卷积层和五个最大池化层、两个全连接层, 图片输入车辆头尾深度学习识别模型中通过第一个卷积层及最大池化层, 获得32个尺寸为 50×50 的特征图; 通过第二个卷积层及最大池化层, 获得64个尺寸为 25×25 的特征图; 通过第三个卷积层及最大池化层, 获得128个尺寸为 12×12 的特征图; 通过第四个卷积层及最大池化层, 获得256个尺寸为 6×6 的特征图; 通过第五个卷积层及最大池化层, 获得512个尺寸为 3×3 的特征图; 然后使用两个全连接层进行连接, 获得1024个尺寸为 1×1 的特征图, 再通过Softmax获得预测分类结果。

5. 根据权利要求1所述的基于卷积神经网络的矿区运输车辆头尾识别方法, 其特征在于: 在所述步骤S3中, 对车辆头尾深度学习识别模型进行训练前进行参数设置, 其中包括设置图片的统一大小为 50×50 ; 设置epoch数为30。

6. 根据权利要求1所述的基于卷积神经网络的矿区运输车辆头尾识别方法, 其特征在于: 在所述步骤S3中, 对车辆头尾深度学习识别模型进行训练时, 设置学习率 lr 为0.001, 对于训练过程的验证误差损失采用公式为 $Loss = -\sum_{i=1}^{output\ size} y_i \times \log \hat{y}_i$ 的多类交叉熵损失函数进行处理, 迭代方法为随机梯度下降, 批处理次数epoch小于等于30。

7. 根据权利要求6所述的基于卷积神经网络的矿区运输车辆头尾识别方法, 其特征在于: 对车辆头尾深度学习识别模型进行训练的模型训练epoch数按3、5、10、15、20、30依次训练。

8. 根据权利要求1所述的基于卷积神经网络的矿区运输车辆头尾识别方法, 其特征在

于,当出现车辆逃逸时还包括以下步骤:

S8:对逃逸车辆拍下图片快照。

9.根据权利要求8所述的基于卷积神经网络的矿区运输车辆头尾识别方法,其特征在于,还包括以下步骤:

S9:对逃逸车辆记录车辆车牌信息。

10.基于卷积神经网络的矿区运输车辆头尾识别系统,采用如权利要求1~9任一项所述的车辆头尾识别方法对车辆出口处车辆的图像进行检测识别,包括:

数据集获取模块,用于进行样本采集、标注,建立车辆头尾目标检测数据集;

模型构建模块,用于构建卷积神经网络车辆头尾深度学习识别模型;

模型训练模块,用于对车辆头尾深度学习识别模型进行训练直到模型收敛,获得最优模型;

模型测试模块,用于对最优模型在进行测试,直到识别精确度达到预期为止:则最优模型为最终车辆头尾识别模型;

检测判断模块,通过最终车辆头尾识别模型判断经过车辆的图片是否是车头图片;若是则允许车辆通过,否则禁止车辆通过;

中央处理模块,用于向其他模块发出指令,完成相关动作;

所述数据集获取模块、模型构建模块、模型训练模块、模型测试模块、模型测试模块均与中央处理模块电连接。

基于卷积神经网络的矿区运输车辆头尾识别方法及系统

技术领域

[0001] 本发明涉及视觉识别技术领域,具体涉及基于卷积神经网络的矿区运输车辆头尾识别方法。

背景技术

[0002] 安徽省矿产资源丰富,很多矿产资源在全国占有重要地位,为地方国民经济持续健康发展提供了重要支撑。随着矿产资源开采规模的不断扩大,对矿山资源开发进行有效监管已成为日趋重要的问题。近年来,国家先后出台了一系列关于矿产资源管理的法律法规和政策,推动了矿业的健康发展,同时也促进了基层矿政管理水平的提高。

[0003] 矿产资源开发中违法违规现象难以杜绝,仍时有发生,存在无证开采、盗采、破坏性开采、不按批准的开发利用方案开采、资源利用率低、瞒报产量、污染环境、安全和地质灾害隐患等一系列问题。靠监管人员巡查难度很大,所花费的人力、物力、财力也很大,而且效果不甚理想,如何做到精准监管成为亟待解决的难题。

[0004] 在矿山复杂环境下,有些运输车拉完资源后可能会逃逸,即这些车辆拉完矿物后逃离监控平台的管理,因为,国家对矿区资源的收税是按照开采量来计算的,这样就会造成偷税漏税现象。另外,对进出矿区的运输车进行车头车尾的识别,能够对运输车所拉资源进行有效的过磅,防止车辆没有过磅或者超载,这有利于资源的有效监控,避免国家税收的丢失具有重要的意义。

[0005] 对矿区运输车的车头车尾进行精细化识别,不仅对于矿山资源的有效管理具有重要的意义,而且还能避免偷税漏税的非法行为。为此,提出基于卷积神经网络的矿区运输车辆头尾识别方法。

发明内容

[0006] 本发明所要解决的技术问题在于:如何解决矿区车辆偷税漏税的非法行为,提高识别的准确性,有利于资源的有效监控,提供了基于卷积神经网络的矿区运输车辆头尾识别方法。

[0007] 本发明是通过以下技术方案解决上述技术问题的,本发明包括以下步骤:

[0008] S1:进行样本采集、标注,建立车辆头尾目标检测数据集;

[0009] S2:构建卷积神经网络车辆头尾深度学习识别模型;

[0010] S3:对车辆头尾深度学习识别模型进行训练直到模型收敛,获得最优模型;

[0011] S4:对最优模型在进行测试,直到识别精确度达到预期为止:则最优模型为最终车辆头尾识别模型;

[0012] S5:通过最终车辆头尾识别模型判断经过车辆的图片是否是车头图片;若是则允许车辆通过,否则禁止车辆通过。

[0013] 更进一步地,在所述步骤S1中,采集矿区运输车辆车头的样本与矿区运输车辆车尾的图片样本,并通过人工手动将图片样本分成车头和车尾两类作为训练集。

[0014] 更进一步地,在所述步骤S1中,矿区运输车辆车头的样本与矿区运输车辆车尾的图片样本数量均大于等于10000张。

[0015] 更进一步地,在所述步骤S2中,车辆头尾深度学习识别模型包括依次间隔设置的五个卷积层和五个最大池化层、两个全连接层,图片输入车辆头尾深度学习识别模型中通过第一个卷积层及最大池化层,获得32个尺寸为 50×50 的特征图;通过第二个卷积层及最大池化层,获得64个尺寸为 25×25 的特征图;通过第三个卷积层及最大池化层,获得128个尺寸为 12×12 的特征图;通过第四个卷积层及最大池化层,获得256个尺寸为 6×6 的特征图;通过第五个卷积层及最大池化层,获得512个尺寸为 3×3 的特征图;然后使用两个全连接层进行连接,获得1024个尺寸为 1×1 的特征图,再通过Softmax获得预测分类结果。

[0016] 更进一步地,在所述步骤S3中,对车辆头尾深度学习识别模型进行训练前进行参数设置,其中包括设置图片的统一大小为50x50;设置epoch(回合)数为30。

[0017] 更进一步地,在所述步骤S3中,对车辆头尾深度学习识别模型进行训练时,设置学习率lr为0.001,对于训练过程的验证误差损失采用公式为 $\text{Loss} = -\sum_{i=1}^{\text{output size}} y_i \times \log \hat{y}_i$ 的多类交叉熵损失函数进行处理,迭代方法为随机梯度下降,批处理次数epoch小于等于30。

[0018] 更进一步地,对车辆头尾深度学习识别模型进行训练的模型训练epoch数按3、5、10、15、20、30依次训练。

[0019] 更进一步地,在所述步骤S5中,通过所述的车辆头尾识别模型判断图片中的车辆是否是车头。

[0020] 更进一步地,当出现车辆逃逸时还包括以下步骤:

[0021] S8:对逃逸车辆拍下图片快照。

[0022] 更进一步地,还包括以下步骤:

[0023] S9:对逃逸车辆记录车辆车牌信息。

[0024] 本发明还提供了基于卷积神经网络的矿区运输车辆头尾识别系统,采用上述的车辆头尾识别方法对车辆出口处车辆的图像进行检测识别,包括:

[0025] 数据集获取模块,用于进行样本采集、标注,建立车辆头尾目标检测数据集;

[0026] 模型构建模块,用于构建卷积神经网络车辆头尾深度学习识别模型;

[0027] 模型训练模块,用于对车辆头尾深度学习识别模型进行训练直到模型收敛,获得最优模型;

[0028] 模型测试模块,用于对最优模型在进行测试,直到识别精确度达到预期为止:则最优模型为最终车辆头尾识别模型;

[0029] 检测判断模块,用于通过最终车辆头尾识别模型判断经过车辆的图片是否是车头图片;若是则允许车辆通过,否则禁止车辆通过;

[0030] 中央处理模块,用于向其他模块发出指令,完成相关动作;

[0031] 所述数据集获取模块、模型构建模块、模型训练模块、模型测试模块、模型测试模块均与中央处理模块电连接。

[0032] 本发明相比现有技术具有以下优点:该基于卷积神经网络的矿区运输车辆头尾识别方法及系统,采用改进的深度学习的识别算法,进行训练直到收敛,然后对车辆进行快速识别,解决了矿区车辆头尾识别的问题,提高了车辆头尾检测的效率,值得被推广使用。

附图说明

- [0033] 图1是本发明实施例一中矿区运输车辆头尾识别方法的流程示意图；
- [0034] 图2是本发明实施例一中算法模型的结构示意图；
- [0035] 图3是本发明实施例二中矿区运输车辆头尾识别方法的流程示意图；
- [0036] 图4是本发明实施例二中矿区运输车辆头尾的快速智能识别界面展示系统框图；
- [0037] 图5是本发明实施例二中矿区运输车辆头尾的快速智能识别界面展示系统的界面示意图。

具体实施方式

[0038] 下面对本发明的实施例作详细说明,本实施例在以本发明技术方案为前提下进行实施,给出了详细的实施方式和具体的操作过程,但本发明的保护范围不限于下述的实施例。

[0039] 实施例一

[0040] 如图1所示,本实施例提供一种技术方案:基于卷积神经网络的矿区运输车辆头尾识别方法,包括以下步骤:

[0041] S1:进行样本采集、标注,建立车辆头尾目标检测数据集;

[0042] S2:构建卷积神经网络车辆头尾深度学习识别模型;

[0043] S3:对车辆头尾深度学习识别模型进行训练直到模型收敛,获得最优模型;

[0044] S4:对最优模型进行测试,直到识别精确度达到预期为止:则最优模型为最终车辆头尾识别模型;

[0045] S5:通过最终车辆头尾识别模型判断图片中是否为车头部分的图片;若是,S6,允许车辆通过,否则,S7,禁止车辆通过。

[0046] 通过采用改进的深度学习的识别算法,进行训练直到收敛,然后对车辆进行快速识别,提高了车辆头尾检测的效率。本实施例的矿区运输车辆头尾的快速智能识别方法,针对不同矿区环境的特点,若采用传统的深度学习算法,效果并不好,则采用改进的深度的识别算法,解决了矿区车辆头尾识别的问题,并提高了识别的准确性。

[0047] 在本实施例中,通过在矿区现场车辆出口处安装至少2个摄像头对车辆头尾进行识别监控。同时,采用了CNN深度学习算法,提高了车辆头尾识别的效率,避免了车辆在出口处的停滞。

[0048] 在本实施例中,对于需要检测车辆不做限定,在进行车辆头尾检测之前,需要将对应的检测对象进行信息输入,使得后续的检测能够对应。

[0049] 在本实施例中,步骤S1包括采集矿区运输车车头样本和车尾样本,并通过人工手动将图片样本分成车头和车尾两类作为训练集。将车辆头尾图片进行样本收集和分类,使得在训练过程中,只需将训练集中已分类好的车辆头尾的图片输入即可开始训练。

[0050] 由于需要提供大量的样本,这样才能提高检测效率,在本实施例中,本发明对于具体的提供的样本数量不做限定,作为较佳的,在所述步骤S1中,矿区运输车(大卡车)车头样本和矿区运输车车尾样本的数量均大于等于10000张。

[0051] 在本实施例中,完成车辆头尾深度学习识别模型建立之后,需要进行训练,本发明对训练方式不做限定,作为较佳的,所述步骤S3中对所述车辆头尾深度学习识别模型进行

训练的具体过程如下：

[0052] 设置学习率 lr 等于0.001；

[0053] 设置图片的统一大小为:50x50；

[0054] 设置回合数(epoch)为:30。

[0055] 如图2所示,本实施例中的算法模型采用了一种深度CNN来提取不同尺度的特征。每批次输入的是32个图片,尺寸为 50×50 ,对2D图片的预测结果进行加权和融合以获得最终分类结果。本实施例的深度CNN具有五层卷积核,这些卷积核用于提取输入的特征,max-pooling内核的大小与每一层的卷积内核相同。通过第一个卷积层及最大池化层,获得32个尺寸为 50×50 的特征图;通过第二个卷积层及最大池化层,获得64个尺寸为 25×25 的特征图。通过第三个卷积层及最大池化层,获得128个尺寸为 12×12 的特征图。通过第四个卷积层及最大池化层,获得256个尺寸为 6×6 的特征图。通过第五个卷积层及最大池化层,获得512个尺寸为 3×3 的特征图。然后使用两个全连接层进行连接,获得1024个尺寸为 1×1 的特征图,再通过Softmax获得预测分类结果,进行预测。

[0056] BP算法作为传统训练多层网络的典型算法,实际上仅含几层网络,该训练方法在该数据集训练效果很不理想。训练困难的主要来源是:深度结构(涉及多个非线性处理单元层)非凸目标代价函数中普遍存在的局部最小。

[0057] BP算法存在的问题:

[0058] (1)梯度越来越稀疏:从顶层越往下,误差校正信号越来越小;

[0059] (2)收敛到局部最小值:尤其是从远离最优区域开始的时候(随机值初始化会导致这种情况的发生);

[0060] (3)一般只能用有标签的数据来训练:但大部分的数据是没标签的。

[0061] 与该传统模型相比,本实施例中的模型在训练和预测上分类准确性表现的更好。

[0062] 实施例二

[0063] 如图3所示

[0064] 本实施例中的基于卷积神经网络的矿区运输车辆头尾识别方法,还包括以下步骤:

[0065] S8:对所述逃逸车辆拍下图片快照;

[0066] S9:对逃逸车辆记录车辆车牌信息,使用矿区已存在的车牌检测系统来实现。

[0067] 如图4所示,本实施例还提供了一种矿区运输车辆头尾的快速智能识别界面展示系统,包括:

[0068] 设置在预定检测区域用于对经过的车辆头尾图片信息获取的摄像装置;

[0069] 与摄像装置连接的数据库服务器,用于通过样本采集、标注,建立车辆头尾目标检测数据集,构建CNN车辆头尾深度学习识别模型,并根据车辆头尾深度学习识别模型对摄像装置输出的车辆进行头尾检测信息进行分析处理,在判断车辆是车头之后,输出车辆检测结果;

[0070] Qt界面展示系统,用于所述车辆头尾检测结果进行显示。

[0071] 如图5所示,为上述矿区运输车辆头尾的快速智能识别界面展示系统的一组实施界面示意图。

[0072] 综上所述,上述实施例的基于卷积神经网络的矿区运输车辆头尾识别方法及系

统,采用改进的深度学习的识别算法,进行训练直到收敛,然后对车辆进行快速识别,解决了矿区车辆头尾识别的问题,提高了车辆头尾检测的效率,值得被推广使用。

[0073] 尽管上面已经示出和描述了本发明的实施例,可以理解的是,上述实施例是示例性的,不能理解为对本发明的限制,本领域的普通技术人员在本发明的范围内可以对上述实施例进行变化、修改、替换和变型。

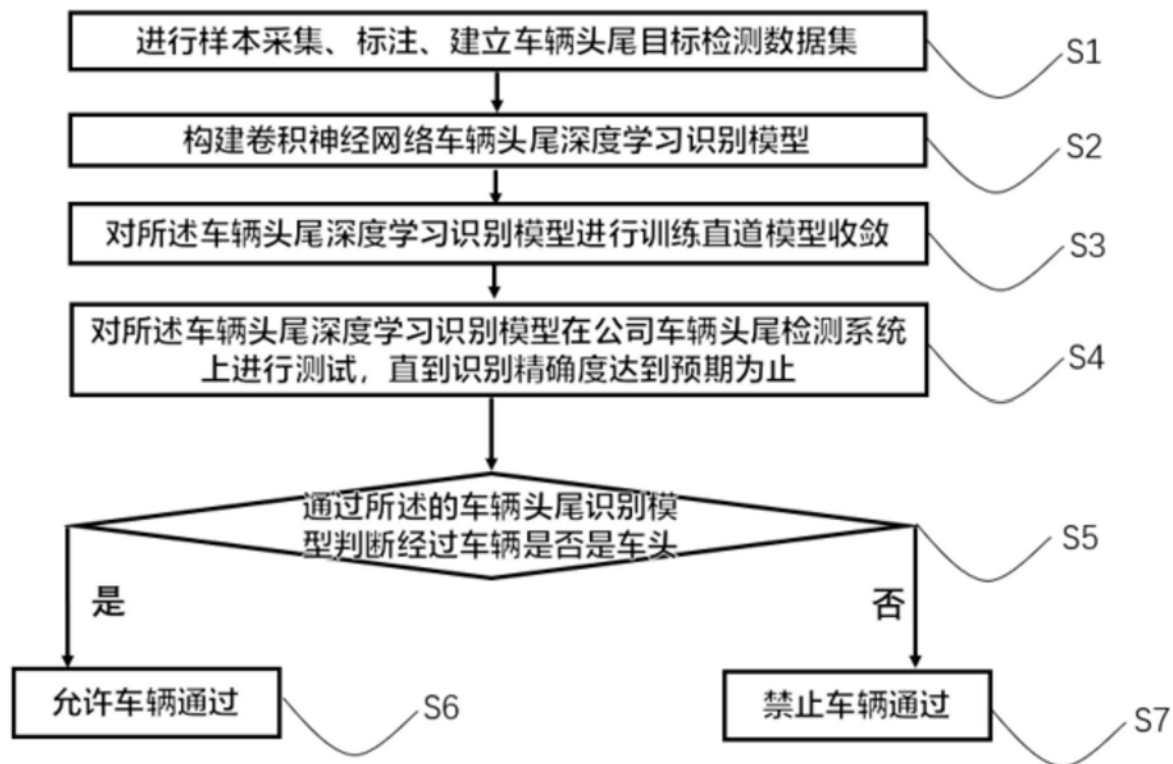


图1




图2

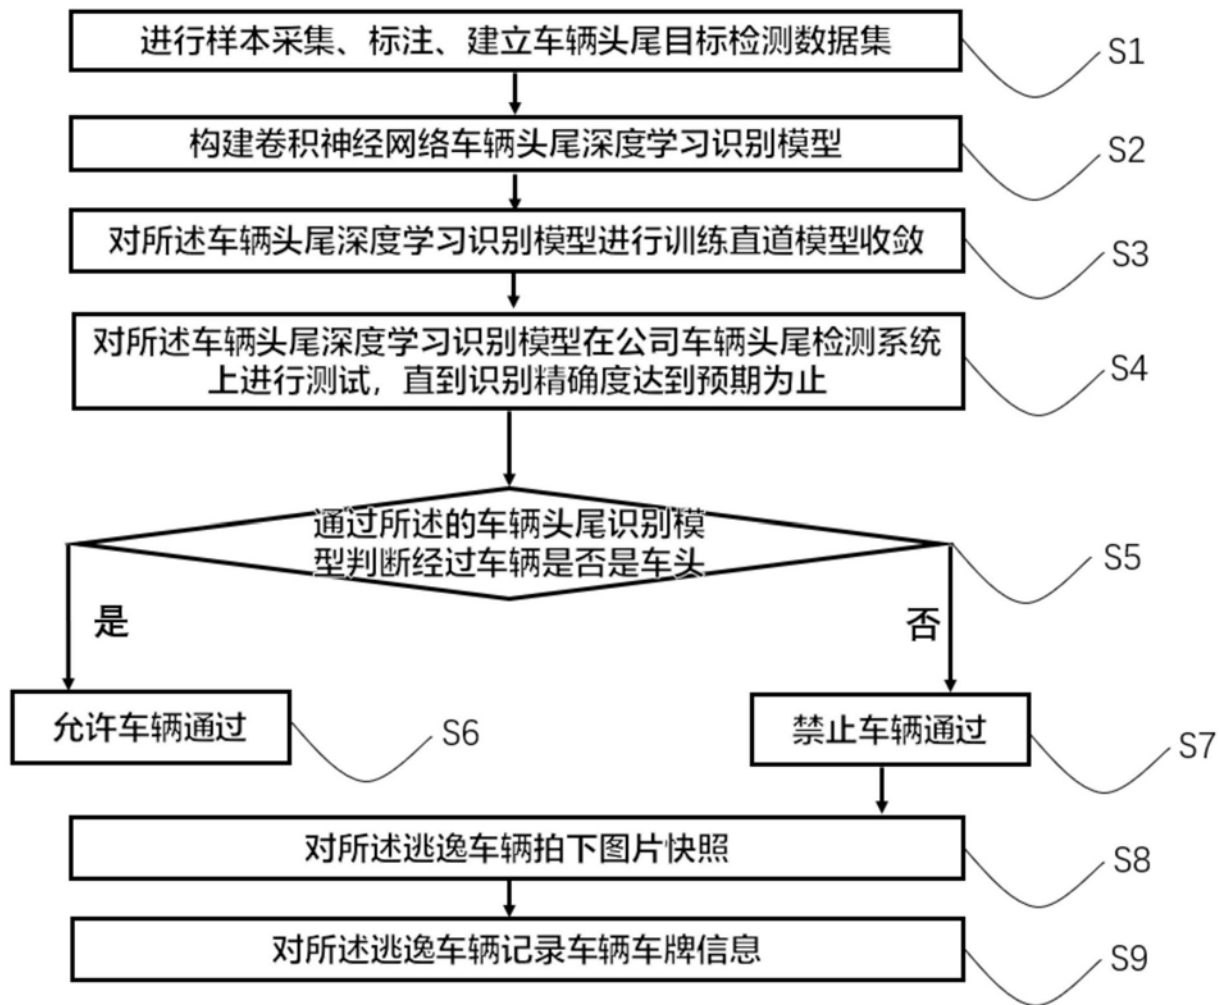


图3

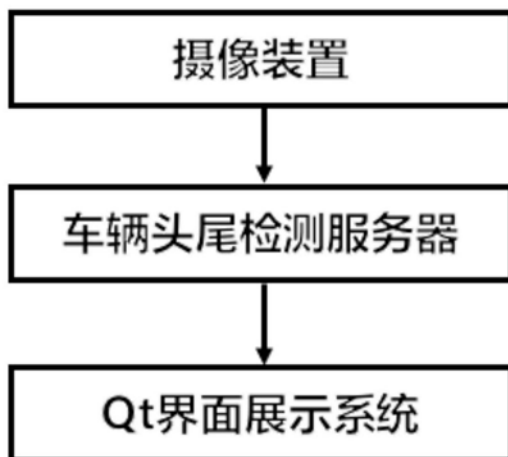


图4



图5